

Prefill Cache Simulation

从“命中多少”到“最少需要多少 P”

本报告回答两个问题：没有 Shared KVS 时，怎样选 Prefill node 才能保住 local prefix cache；有 Shared KVS 后，怎样在 deadline、fairness、queue 和 transfer budget 内，用最少的 P 完成同一份 trace。

TRACE CEILING 57.07% Infinite capacity、no expiry、strict prefix。	LOCAL-ONLY BEST 54.01% 4 P、12,500 blocks/P、LRU、100ms delayed view。	SHARED @ P=2 + 165 STRICT requests 按时数：3,701→3,866。	边界 ≠ MFU Normalized simulation：真实秒数等待硬件标定。
--	---	--	---

一句话结论

Local-only 世界里，stable prefix owner 最值钱；Shared KVS 世界里，最值钱的是把 local hit、remote fetch 和 queue 放进同一张 SLO 成本账，再据此做 resource sizing。

署名：张珮文。每个数字会标明 trace 观测、simulation 输出或 synthetic assumption。

数据给了 block hash，也给了 input token 数

Item	数字	怎么理解	不能反推什么
Requests	23,608; 0~3,600,000ms; 1,180 个 unique timestamps	按 timestamp 回放; 同 timestamp 会形成 burst。	不是平滑 QPS。
Input	202,791,701 tokens; mean 8,589.96; median 6,345; p95 26,078.55	request 级 input token 总数是 trace truth。	看不到 token 文本。
Output	4,299,817 tokens; mean 182.13; median 30; p95 600	用于 Decode work。	没有逐 token 时间。
Blocks	409,356 references; 183,166 unique	一个 full hash block 代表 512 tokens; 23,581 requests 有 partial tail。	hash 不是 token，不能做 block 内匹配。
Session	无 session_id	只能用共享 prefix 做 online family proxy。	不能声称恢复真实会话。

TOKEN-WEIGHTED HIT

- full block 命中计 512 tokens。
- 最后 partial block 用 input_tokens 还原实际 token 数。
- 只统计从第一个 block 开始连续命中的 prefix。

57.07% 的前提

- 容量无限、永不过期。
- 所有历史 request 对当前 request 可见。
- 不计 local 分片、transfer、queue、故障。

token_weighted_hit = 连续命中的实际 prefix tokens / 全部 input tokens
= 115,733,271 / 202,791,701
= 57.0700%

没有 Shared KVS：selector 要把复用流量聚回同一台 P

策略	规则	Token hit	收益	瓶颈
Random	alive P 中均匀随机。	44.30%	无偏 baseline。	prefix 被打散。
Round Robin	按 request 次序轮转。	44.25%	request count 均衡。	不理解 token work。
Least Work	选 running + queued work 最少的 P。	43.67%	负载感知。	进一步打散 locality。
Prefix owner + fallback	前 2 个 block 形成 stable owner；owner 过载时只看 2 个 deterministic fallback。	54.01%	重复 prefix 回到同一 owner。	热 prefix 单点；k=2 是 trace-specific sweep。
Session proxy	最长共享 prefix 形成 family，再 sticky 到 owner。	53.34% (proxy)	接近连续上下文。	无真实 session_id。
中心化 master	综合 queue、input、estimated local hit 排序。	53.01% fresh；52.32% delayed	fresh view 下兼顾 hit 与 queue。	stale-view herding。

PREFIX OWNER 的四步

- 1. 取 request 前两个 block hash，k=2 不是“相邻两台 node”。
- 2. SHA-256(key) % N，N 是当前 alive P 数，得到 stable owner。
- 3. 用 normalized queued token-work 判断 owner 是否超过 1.25× cluster mean。
- 4. 过载时看 hash ring 上后续两个候选，选其中 least-work；不是按命中率 top2。

100MS 的准确含义

不是 selector 运行了 100ms，而是 master 读取的 node snapshot 已经老了 100ms。来源可包括 heartbeat 周期、网络、聚合和排队。所有依赖 snapshot 的策略使用同一 causal view；stable owner 映射本身不依赖 fresh ranking。

Global 可见不等于每次都 remote fetch

LOCAL HIT

0 transfer

目标 P 已有 KV。

REMOTE HIT

0.01 work/token

Shared KVS 有 KV，但目标 P 没有。

MISS

0.06 work/token

P 必须重新计算。

成本全部是 round-number assumption

量	值	大白话	性质
Decode	1.00 work/token	定义 Decode 1 token 的计算成本为 1 work。	单位定义。
Prefill miss	0.06 work/token	假设 Prefill 1 input token 只需 Decode token 的 6%。	Synthetic assumption。
Remote KV	0.01 work/token	假设搬 1 token 的 KV 需 Decode token 的 1%。	Synthetic assumption。
KV traffic	65,536 bytes/token	只做流量记账；512-token full block=32MiB。	模型尺寸 assumption，不是 trace 字段。

```
uncached_tokens = input_tokens - local_hit_tokens - remote_hit_tokens
P_gpu_work      = uncached_tokens × 0.06
KVS_work        = remote_hit_tokens × 0.01
D_gpu_work      = output_tokens × 1.00
KV_bytes        = remote_hit_tokens × 65,536
```

PRICED-SPILL SELECTOR

- 1. 每台 eligible P 先算 local prefix。
- 2. Shared 开启时再算可以 remote fetch 的 prefix。
- 3. score=queue+recompute work+remote transfer work。
- 4. 预计超过该 request SLO slack 的 P 先淘汰。
- 5. 剩余候选取 score 最小；相近时选最久未被选的 P，降低 herding。

为什么有 KVS 也不一定取

ZERO_TRANSFER_PRICE_CONTROL 把 remote price 设成 0 后，P8 remote tokens 从正常 Shared 的约 13M 增至约 33M。可见“KVS 中存在”只是可选项；是否取用由 transfer price 与 recompute/queue 的比较决定。

04 · REPLAY CONTRACT

代码简单回放了什么

阶段	输入	kernel 动作	证据
Arrival	timestamp、tokens、hash_ids	按时间发出 23,608 logical requests；same-time priority 固定。	offered/completed ledger。
Placement	causal cache snapshot、P queue、KVS price	selector 返回唯一 P/D；不能读取未来。	decision fingerprint、local/remote/miss tokens。
Prefill	miss+remote tokens	P 串行执行 recompute 与 modeled transfer，记录 READY/START/FINISH。	actual queue wait、P modeled utilization。
Decode	true output tokens	D pool 执行 output work；resource sizing 不启用 abort/retry。	D modeled utilization、completion。
Cache	完成 request 的 prefix keys	本实验 capacity 大于 unique keys：admit all、no eviction。	结束时每个 P 的 alive blocks。
Gate	deadline、fairness、queue、KVS budget	全部门槛通过才认为该 P 数可行。	minimum feasible P 与 P-1 失败证据。

两套实验不能混

54.01% local-only 实验：4 P、12,500 blocks/P、LRU、100ms delayed view。Resource-sizing 实验：P=1...8、no eviction、normalized work clock。数字可并列讲，但不能直接比较高低。

为什么不写 1S / 1.5S / 2S

$deadline_ms = deadline_work \div service_rate_work_per_ms$ 。没有目标 GPU 的实测 service rate，就只能报告 deadline multiplier。写秒数会是假精度。

“SLO”是每条 request 的 deadline；“80%”是按时比例

Gate	Baseline	Strict sensitivity	说明
Tier deadline	STRICT 5,000; STANDARD 20,000; RELAXED 100,000 work-time		不是秒。
Completion	100%	100%	所有 offered request 最终完成。
Minimum-tier attainment	≥80%	≥95%	三个 tier 分别算按时率，取最差的一个。
Jain fairness	≥0.90	≥0.90	不同 synthetic tenant 的服务不能差太远。
P queue p95	≤20,000 work	≤20,000 work	这是 backlog gate，不是 ms。
KVS bytes/work	≤1,000,000	≤1,000,000	这是 modeled transfer budget，不是真实链路 GB/s。

门槛	Local-only N*	Shared KVS N*	P-1 为什么失败
最差 tier ≥80%	3	2	Local P2: STRICT 3,701/4,780=77.43%<80%; Shared P2=3,866/4,780=80.88%。
最差 tier ≥95%	4	4	P3: Local 4,504/4,780=94.23%; Shared 4,485/4,780=93.83%，都未过 95%。

可量化结论

在 baseline 80% gate 下，Shared KVS 把最小 P 从 3 台降到 2 台，减少 1/3；gate 收紧到 95% 后，两种 topology 都要 4 台，省节点收益消失。

Deadline 松紧、queue、utilization 和 alive blocks

DEADLINE SENSITIVITY 的准确语义

只把三个 tier deadline 同比乘 0.5x~2.0x，并重新计算 per-tier attainment 与 Jain fairness；routing、执行顺序、service cost、queue gate 和 KVS gate 全部冻结。它回答“同一批执行结果换一条 deadline 线会怎样”，不是 policy-aware reroute。

Deadline	Local N*	Shared N*	结论
0.50x	≤8 无解	≤8 无解	deadline 砍半后，最差 tier gate 无法通过；禁止外推。
0.75x	3	3	两者都需要 3 P；Shared 不省资源。
1.00x	3	2	唯一本 sweep 中 Shared 少 1 P 的点：3→2，减少 33.3%。
1.25x	2	2	deadline 放宽后 Local 也降到 2 P，Shared 优势消失。
1.50x	2	2	受 P=1 的 queue/fairness gate 限制，不能继续降。
2.00x	2	2	继续放宽 deadline 也不能把 P 从 2 降到 1。

同样 P 的 operational head-to-head

Case	Token hit	Actual P queue wait p95	P/D modeled utilization	Final alive blocks/P
Local P2	54.62%	7,178.22 work-time	P 46.02% / D 8.96%	mean 96,450.5；95,325~97,576
Shared P2	56.80%	6,409.96 work-time	P 43.80% / D 8.96%	mean 100,995.5；100,636~101,355
Local P4	54.56%	1,484.04 work-time	P 23.04% / D 8.96%	mean 48,283.5；46,832~50,031
Shared P4	56.83%	1,422.84 work-time	P 21.89% / D 8.96%	mean 52,726.0；51,774~54,120

P=2 的量化收益

- Token hit +2.18pp。
- Actual queue wait p95 下降 768.26 work-time，-10.70%。
- P modeled utilization 46.02%→43.80%，说明 remote fetch 替换了部分 recompute。
- STRICT on-time requests 多 165 条，刚好跨过 80% gate。

为什么 ALIVE BLOCKS/P 反而更多

- Shared P2 的 mean final alive blocks 比 Local 多 4,545，+4.71%。
- 原因是每个 P 在 request 完成后仍 admit 全部 prefix；不同路由会产生副本。
- 本 sizing 是 no eviction，因此这是“结束时 resident keys”，不是显存容量需求。
- 真实 TTL/LRU 会改变这条曲线，不能直接换算 GPU memory。

07 · DECISION

最值钱的不是继续追 3pp hit，而是 cache-aware resource substitution

可以落地

- Local-only: stable prefix owner + bounded load fallback。
- Shared: priced spill, remote 只有比 recompute/queue 更便宜时才取。
- Autoscaling: 按最差 tier attainment + queue + fairness 选最小 P。
- Shadow 指标: local/remote/miss、snapshot age、actual wait、transfer bytes。

仍需硬件验证

- work-time 到 ms 的标定。
- KV bytes/token 与具体模型、dtype、TP 的关系。
- 真实 KVS bandwidth/contention。
- 真实 GPU MFU；当前只有 modeled issued-work utilization。
- capacity/TTL/eviction 下的 alive block 曲线。

最大价值

- Local-only 54.01% 已接近 57.07% trace ceiling，继续追 hit 的空间有限且容易制造 hotspot。
- Shared KVS 把 cache reuse 变成可定价的资源替代：少算多少 Prefill、搬多少 KV、少用几台 P、最差 tier 是否仍按时。
- Shared 不是无条件 winner：旧 floor sensitivity 在 0.94 和 0.96 出现反转，说明 transfer/routing 也会伤害严格 SLO。

DECODE LEASE

它应作为 overload protection 单独验证。已有 sensitivity 曾出现 hit 76.11%，但 attempts 41,403、retries 17,795、gated 14,881，strict output goodput 下降；retry 制造的额外 hit 不是免费收益。

Evidence root: results/m12-sizing-v1.2; final publication 必须 pin git SHA、schema、MANIFEST SHA-256。